Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Отчет по лабораторной работе №5

по дисциплине «Методы машинного обучения»

по теме «Обучение на основе временных различий»

Выполнил:
студент группы № ИУ5-24М
Винников С.С.
подпись, дата

Проверил:

подпись, дата

2024 г.

Задание:

На основе рассмотренного на лекции примера реализуйте следующие алгоритмы:

- SARSA
- Q-обучение
- Двойное Q-обучение

для любой среды обучения с подкреплением (кроме рассмотренной на лекции среды Toy Text / Frozen Lake) из библиотеки Gym (или аналогичной библиотеки).

Текст программы

BasicAgent.py

```
class BasicAgent: #Базовый агент, от которого наследуются стратегии обучения

 # Наименование алгоритма
 ALGO_NAME = '---'

 def __init__(self, env, eps=0.1):
 # Среда
 self.env = env
 # Размерности Q-матрицы
 self.nA = env.action space.n
 self.nS = env.observation_space.n
 #и сама матрица
 self.Q = np.zeros((self.nS, self.nA))
 # Значения коэффициентов
 # Порог выбора случайного действия
 self.eps=eps
 # Награды по эпизодам
 self.episodes_reward = []

 def print q(self):
 print('Вывод Q-матрицы для алгоритма ', self.ALGO_NAME)
 print(self.Q)

 def get_state(self, state): #Возвращает правильное начальное состояние

 if type(state) is tuple:
 # Если состояние вернулось с виде кортежа, то вернуть только номер состояния  return
state[0]
 else:
 return state

 def greedy(self, state):
 '''
 <<Жадное>> текущее действие
 Возвращает действие, соответствующее максимальному Q-значению  для
состояния state
 '''
 return np.argmax(self.Q[state])

 def make_action(self, state): #Выбор действия агентом

 if np.random.uniform(0,1) < self.eps:

 # Если вероятность меньше eps
 # то выбирается случайное действие
 return self.env.action_space.sample()
 else:
 # иначе действие, соответствующее максимальному Q-значению  return
self.greedy(state)

 def draw episodes reward(self):
 # Построение графика наград по эпизодам
 fig, ax = plt.subplots(figsize = (15,10))
 y = self.episodes reward
 x = list(range(1, len(y)+1))
 plt.plot(x, y, '-', linewidth=1, color='green')
 plt.title('Награды по эпизодам')
 plt.xlabel('Номер эпизода')
 plt.ylabel('Награда')
 plt.show()
```

```
 def learn(self):
 '''
 Реализация алгоритма обучения
 '''
 pass
```

DoubleQLearning_Agent.py

```
class DoubleQLearning_Agent(BasicAgent):
 '''
 Реализация алгоритма Double Q-Learning
 '''
 # Наименование алгоритма
 ALGO_NAME = 'Двойное Q-обучение'

 def   init  (self, env, eps=0.4, lr=0.1, gamma=0.98, num_episodes=20000):  #
Вызов конструктора верхнего уровня
 super().  init  (env, eps)
 # Вторая матрица
 self.Q2 = np.zeros((self.nS, self.nA))
 # Learning rate
 self.lr=lr
 # Коэффициент дисконтирования
 self.gamma = gamma
 # Количество эпизодов
 self.num episodes=num episodes
 # Постепенное уменьшение eps
 self.eps decay=0.00005
 self.eps_threshold=0.01


 def greedy(self, state):
 '''
 <<Жадное>> текущее действие
 Возвращает действие, соответствующее максимальному Q-значению  для
состояния state
 '''
 temp q = self.Q[state] + self.Q2[state]
 return np.argmax(temp_q)

 def print q(self):
 print(f"Вывод Q-матриц для алгоритма {self.ALGO_NAME}")
 print('Q1')
 print(self.Q)
 print('Q2')
 print(self.Q2)

 def learn(self):
 '''
 Обучение на основе алгоритма Double Q-Learning
 '''
 self.episodes reward = []
 # Цикл по эпизодам
 for ep in tqdm(list(range(self.num_episodes))):
 # Начальное состояние среды
 state = self.get state(self.env.reset())
 # Флаг штатного завершения эпизода
 done = False
 # Флаг нештатного завершения эпизода
 truncated = False
 # Суммарная награда по эпизоду
 tot_rew = 0

 # По мере заполнения Q-матрицы уменьшаем вероятность случайного выбора действия  if self.eps >
self.eps threshold:
 self.eps -= self.eps_decay

 # Проигрывание одного эпизода до финального состояния
 while not (done or truncated):
 # Выбор действия
 # В SARSA следующее действие выбиралось после шага в среде  action =
self.make_action(state)

 # Выполняем шаг в среде
                 next_state, rew, done, truncated, _ = self.env.step(action)

 if np.random.rand() < 0.5:
 # Обновление первой таблицы
                       self.Q[state][action] = self.Q[state][action] + self.lr * \
```

```
 (rew + self.gamma *
self.Q2[next_state][np.argmax(self.Q[next_state])] - self.Q[state][action])
else:
 # Обновление второй таблицы
                        self.Q2[state][action] = self.Q2[state][action] + self.lr * \
 (rew + self.gamma *
self.Q[next_state][np.argmax(self.Q2[next_state])] - self.Q2[state][action])

 # Следующее состояние считаем текущим
 state = next state
 # Суммарная награда за эпизод
                 tot rew += rew
 if (done or truncated):
 self.episodes_reward.append(tot_rew)
```

QLearning_Agent.py

```
class QLearning_Agent(BasicAgent):
 '''
 Реализация алгоритма Q-Learning
 '''
 # Наименование алгоритма
 ALGO_NAME = 'Q-обучение'

 def   init  (self, env, eps=0.4, lr=0.1, gamma=0.98, num_episodes=20000):  #
Вызов конструктора верхнего уровня
 super().  init _(env, eps)
 # Learning rate
 self.lr=lr
 # Коэффициент дисконтирования
 self.gamma = gamma
 # Количество эпизодов
 self.num episodes=num episodes
 # Постепенное уменьшение eps
 self.eps decay=0.00005
 self.eps_threshold=0.01

 def learn(self):
 '''
 Обучение на основе алгоритма Q-Learning
 '''
 self.episodes reward = []
  # Цикл по эпизодам
 for ep in tqdm(list(range(self.num_episodes))):
 # Начальное состояние среды
 state = self.get state(self.env.reset())
 # Флаг штатного завершения эпизода
 done = False
 # Флаг нештатного завершения эпизода
 truncated = False
 # Суммарная награда по эпизоду
 tot_rew = 0

 # По мере заполнения Q-матрицы уменьшаем вероятность случайного выбора действия  if self.eps >
self.eps_threshold:
 self.eps -= self.eps_decay

 # Проигрывание одного эпизода до финального состояния
 while not (done or truncated):
 # Выбор действия
      # В SARSA следующее действие выбиралось после шага в среде action =
                            self.make_action(state)

 # Выполняем шаг в среде
                 next_state, rew, done, truncated, _ = self.env.step(action)

 # Правило обновления Q для SARSA (для сравнения)
 # self.Q[state][action] = self.Q[state][action] + self.lr * \  # (rew +
self.gamma * self.Q[next_state][next_action] - self.Q[state][action])

 # Правило обновления для Q-обучения
 self.Q[state][action] = self.Q[state][action] + self.lr * \  (rew + self.gamma *
np.max(self.Q[next_state]) - self.Q[state][action])

 # Следующее состояние считаем текущим
                 state = next state
 # Суммарная награда за эпизод
                 tot rew += rew
 if (done or truncated):
```

```
 self.episodes_reward.append(tot_rew)
```

SARSA_Agent.py

```
class SARSA_Agent(BasicAgent):
 '''
 Реализация алгоритма SARSA
 '''
 # Наименование алгоритма
 ALGO_NAME = 'SARSA'

 def   init  (self, env, eps=0.4, lr=0.1, gamma=0.98, num_episodes=20000):  #
Вызов конструктора верхнего уровня
 super().  init _(env, eps)
 # Learning rate
 self.lr=lr
 # Коэффициент дисконтирования
 self.gamma = gamma
 # Количество эпизодов
 self.num episodes=num episodes
 # Постепенное уменьшение eps
 self.eps decay=0.00005
 self.eps_threshold=0.01

 def learn(self):
 '''
 Обучение на основе алгоритма SARSA
 '''
 self.episodes reward = []
 # Цикл по эпизодам
 for ep in tqdm(list(range(self.num_episodes))):
 # Начальное состояние среды
 state = self.get state(self.env.reset())
  # Флаг штатного завершения эпизода
 done = False
 # Флаг нештатного завершения эпизода
 truncated = False
 # Суммарная награда по эпизоду
 tot_rew = 0

 # По мере заполнения Q-матрицы уменьшаем вероятность случайного выбора действия  if self.eps >
self.eps threshold:
 self.eps -= self.eps_decay

 # Выбор действия
 action = self.make action(state)
 # Проигрывание одного эпизода до финального состояния  while not
(done or truncated):
 # Выполняем шаг в среде
 next_state, rew, done, truncated, _ = self.env.step(action)

 # Выполняем следующее действие
 next_action = self.make_action(next_state)

 # Правило обновления Q для SARSA
                 self.Q[state][action] = self.Q[state][action] + self.lr * \
(rew + self.gamma * self.Q[next_state][next_action] - self.Q[state][action])

 # Следующее состояние считаем текущим
                 state = next_state
 action = next action
 # Суммарная награда за эпизод
                 tot rew += rew
 if (done or truncated):
 self.episodes_reward.append(tot_rew)
```

main.py

```
def play_agent(agent):
 '''
 Проигрывание сессии для обученного агента
 '''
 env2 = gym.make('Taxi-v3', render_mode='human')
 state = env2.reset()[0]
 done = False
 while not done:
 action = agent.greedy(state)
```

```
 next state, reward, terminated, truncated, _ = env2.step(action)
env2.render()
 state = next state
 if terminated or truncated:
 done = True


def run sarsa():
 env = gym.make('Taxi-v3')
 agent = SARSA_Agent(env)
 agent.learn()
 agent.print q()
 agent.draw episodes_reward()
 play_agent(agent)


def run q learning():
 env = gym.make('Taxi-v3')
 agent = QLearning_Agent(env)
 agent.learn()
 agent.print q()
 agent.draw episodes_reward()
 play_agent(agent)


def run double q learning():
 env = gym.make('Taxi-v3')
 agent = DoubleQLearning_Agent(env)
 agent.learn()
 agent.print q()
 agent.draw episodes_reward()
 play_agent(agent)

def main():
 run q learning()
 run sarsa()
 run_double_q_learning()


if   name__ == '__main__':
 main()
```

Экранные формы

```
C:\Users\Pes_Tick\PycharmProjects\Laba_5\Scripts\python.exe C:/Users/Pes_Tick/Documents/GitHub/MMO/Laba_5/main.py
100%|██████████| 20000/20000 [00:07<00:00, 2653.45it/s]
Вывод Q-матрицы для алгоритма  Q-обучение
[[ 0.         0.         0.         0.         0.         0.       ]
 [ 5.52143126  6.86775597  5.74511127  6.0405223   8.36234335 -2.78936583]
 [ 9.72193748 10.70101343  7.71265927 11.0275632  13.27445578  2.18438377]
 ...
 [-1.17120277 13.79807389 -0.55308959  1.29691931 -4.80450688 -4.97349337]
 [-2.95120294  7.88467449 -2.98882175 -2.81009845 -6.16536252 -5.79958292]
 [ 2.92342313  7.63251837  1.59493208 18.59777911  0.66544083  2.1632928 ]]
100%|██████████| 20000/20000 [00:06<00:00, 2942.22it/s]
Вывод Q-матрицы для алгоритма  SARSA
[[ 0.          0.          0.          0.          0.          0.       ]
 [ -4.89048373  -4.06559968  -6.48184181  -7.29149042   7.03167409
  -15.88756845]
 [  0.64473492   1.24104148   0.9805527    4.72911114  12.8611346
   -2.73524457]
 ...
 [ -3.21175813   7.53827108  -2.79826233  -3.42775864  -4.7948677
   -7.22347721]
 [ -6.69691937  -6.88658671  -6.5703318   -6.66563988 -12.13549877
  -10.0378743 ]
 [  5.52685166   1.18190491   8.83947059  18.51530708  -1.36262535
    0.96043514]]
```

```
100%|██████████| 20000/20000 [00:08<00:00, 2424.23it/s]
Вывод Q-матриц для алгоритма Двойное Q-обучение
Q1
[[ 0.          0.          0.          0.          0.
   0.        ]
 [ 1.63853371 -1.0381934  -3.99289827  2.46775567  8.36234335
  -6.16494027]
 [ 0.46091158  7.09691525  1.69797111  5.13650562 13.27445578
   0.508859  ]
 ...
 [ 5.7242938  14.5657712   5.55199323  7.72082775 -1.29105504
  -1.1767286 ]
 [-4.41801169 -4.00285875 -4.74259869  0.75479753 -9.9385444
 -10.46810947]
 [ 4.16798562  2.01402328  1.18758792 18.30237288 -0.71683691
  -1.44856652]]
Q2
[[ 0.00000000e+00  0.00000000e+00  0.00000000e+00  0.00000000e+00
   0.00000000e+00  0.00000000e+00]
 [ 5.17987161e-03 -1.80363289e+00 -4.58876168e+00  2.84730552e+00
   8.36234335e+00 -4.29104368e+00]
 [ 5.5e596834e+00  7.80888479e+00  3.54967900e+00  9.47751186e+00
   1.32744558e+01 -1.80929173e-01]
 ...
 [ 8.85848661e+00  1.45657712e+01  7.75419242e+00  5.31000895e+00
   2.67109603e-01 -2.83947872e+00]
 [-4.61752088e+00 -4.45744416e+00 -4.16808700e+00  6.31669213e+00
  -8.51151633e+00 -8.78763830e+00]
 [ 3.52284865e+00  4.49186663e+00  2.62503908e+00  1.84189537e+01
   5.21719516e-01  4.29845406e-01]]
```

q_learning

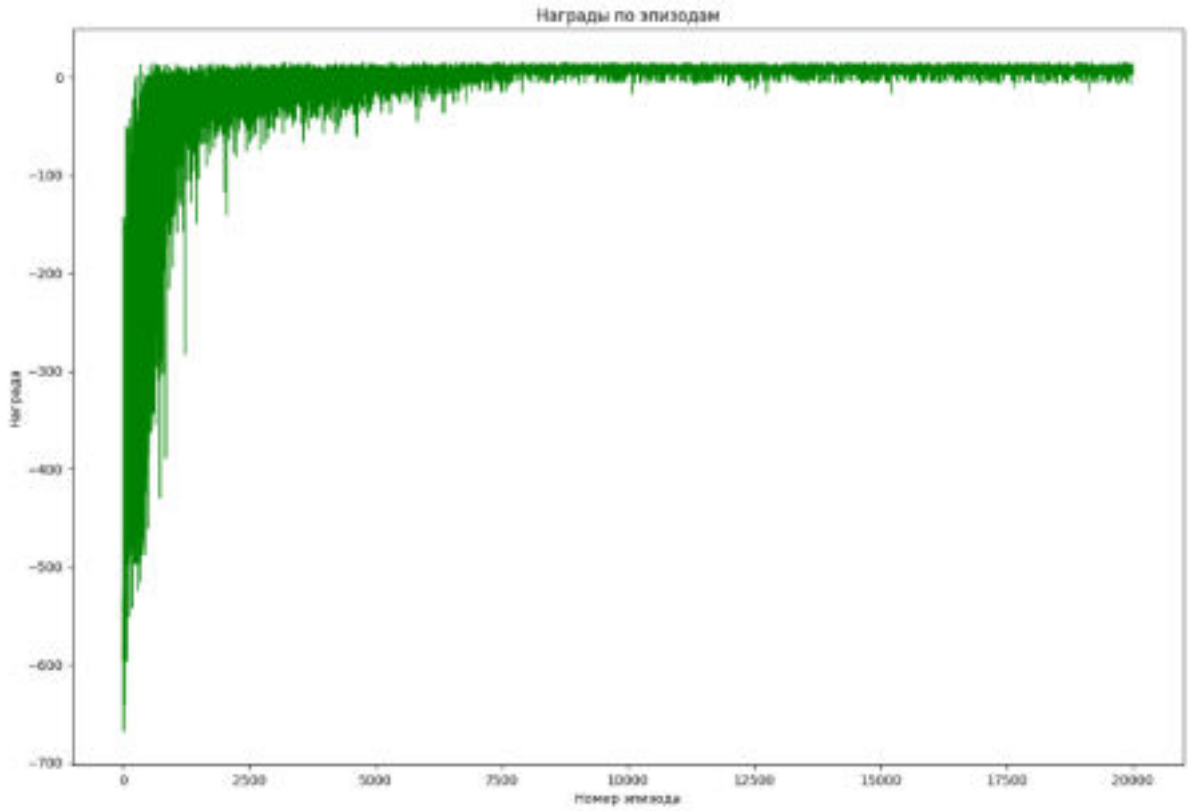

sarsa

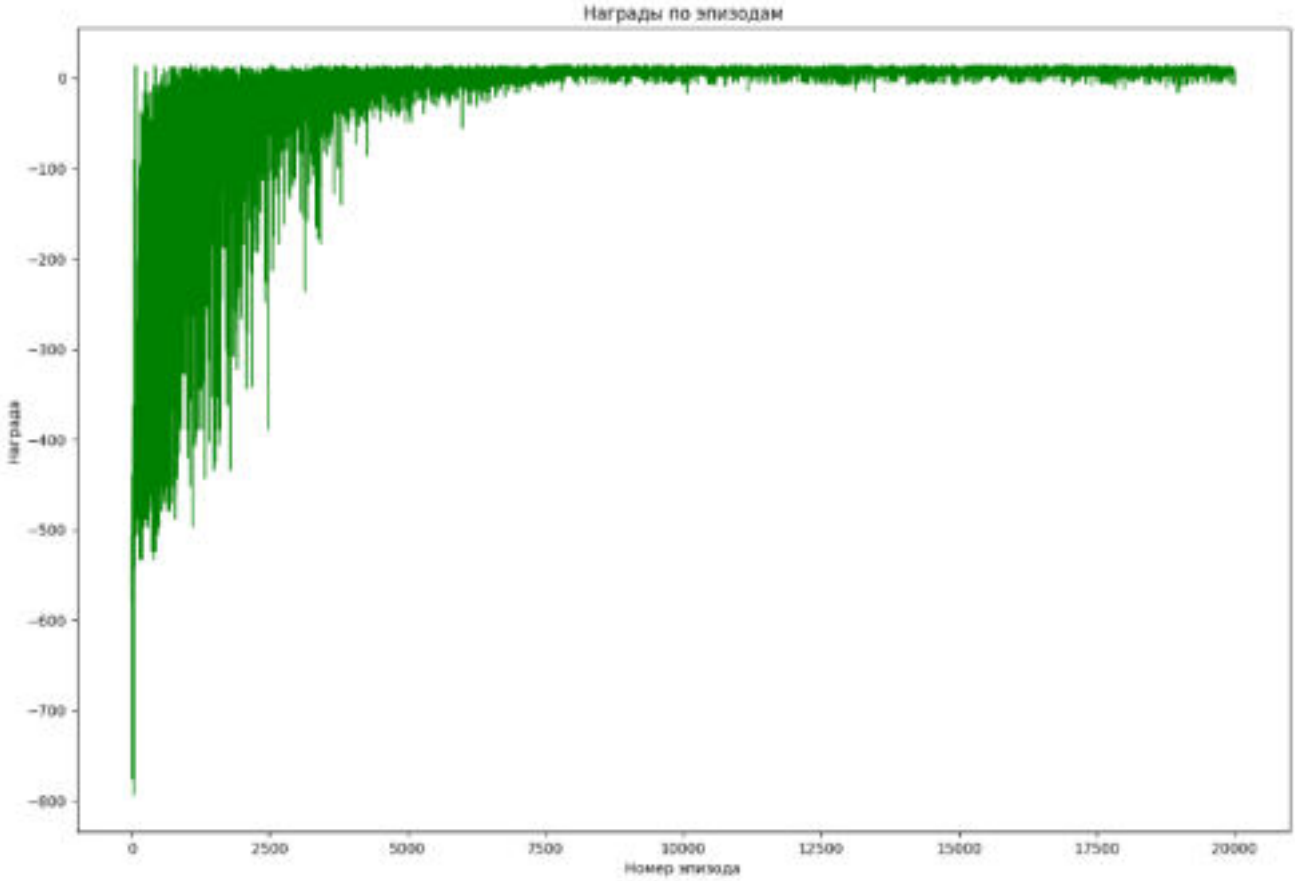

double_q_learning